

UNIVERSIDADE SÃO JUDAS TADEU

Saúde Mental & Burnout no TI

UC: Inteligência Artificial

ESO1AN-MCD-67370187

Gustavo Pereira Soggia – 824147271

Kaic Cavalcanti Pereira – 824155037

Kaique Santos Diniz – 824155790

Pedro Antônio Couto de Carvalho – 825211344

Rafaela de Carvalho Antar – 823117359

Wanderlei Luis Mayta Mamani – 824145077

Gustavo Pereira Soggia – 824147271

Kaic Cavalcanti Pereira – 824155037

Kaique Santos Diniz – 824155790

Pedro Antônio Couto de Carvalho – 825211344

Rafaela de Carvalho Antar – 823117359

Wanderlei Luis Mayta Mamani – 824145077

Saúde Mental & Burnout no TI

UC: Inteligência Artificial

Trabalho semestral apresentado a graduação de Engenharia de Software da Universidade São Judas Tadeu, orientado pelos Profs. Marcelo Duduchi Feitosa e Adavilson Martins Pins, como requisito parcial para aprovação no componente de Inteligência Artificial.

1. RELATÓRIO

Este trabalho tem como objetivo aplicar técnicas de Inteligência Artificial e Aprendizado de Máquina na análise de dados relacionados à saúde mental de profissionais da área de Tecnologia da Informação (TI). Para isso, foi utilizada a base de dados *Employee Mental Health & Burnout Dataset*, que reúne informações de aproximadamente 150 mil funcionários e contém variáveis associadas ao bem-estar psicológico e aos níveis de burnout.

Ao longo do projeto, foram realizadas etapas de pré-processamento dos dados, incluindo a conversão de variáveis categóricas para valores numéricos e o tratamento de dados ausentes. Em seguida, foram treinados e avaliados diferentes modelos de aprendizado de máquina, com o objetivo de prever os níveis de burnout dos indivíduos presentes na base.

Os modelos selecionados para a análise foram Árvore de Decisão, KNN (K Nearest Neighbors) e Regressão Logística. Além da avaliação individual de cada algoritmo, também foi desenvolvido um comitê de classificação baseado em votação majoritária, buscando combinar as previsões dos modelos e explorar diferentes perspectivas sobre os dados.

Por meio da comparação dos resultados obtidos, foi possível analisar o desempenho de cada abordagem e verificar a viabilidade do uso de técnicas de Inteligência Artificial para a identificação de padrões relacionados ao burnout e à saúde mental no ambiente de trabalho.

2. DESCRIÇÃO DA BASE DE DADO

A base de dados escolhida tem como objetivo reunir aproximadamente 150 mil registros de profissionais da área de Tecnologia da Informação (TI), contendo informações relacionadas à saúde mental desses colaboradores. O foco principal do conjunto de dados é a análise do burnout, permitindo a identificação de padrões e fatores associados ao esgotamento físico e emocional no ambiente de trabalho.

3. DEFINIÇÃO DO PROBLEMA

O problema abordado neste trabalho é a incidência de transtornos e condições relacionadas à saúde mental entre profissionais da área de Tecnologia da Informação (TI), como burnout, estresse e depressão. Diante desse cenário, o objetivo é identificar quais características e fatores estão mais associados ao desenvolvimento dessas condições, por meio da análise dos dados disponíveis.

Além disso, busca-se treinar modelos de Inteligência Artificial capazes de realizar previsões sobre o nível de burnout de um indivíduo com base em suas características e condições de trabalho, contribuindo para a identificação de possíveis fatores de risco e para a compreensão dos padrões presentes no conjunto de dados.

4. PRÉ-PROCESSAMENTO

O pré-processamento dos dados foi dividido em duas etapas principais, com o objetivo de preparar a base para o treinamento dos modelos de Inteligência Artificial.

Na primeira etapa, foi realizada a conversão de dados categóricos para valores numéricos por meio da técnica de codificação (*Label Encoding*). Essa transformação foi necessária porque algumas variáveis presentes na base de dados estavam armazenadas como texto, impedindo sua utilização pelos algoritmos de aprendizado de máquina. Além disso, a variável alvo também foi convertida para formato numérico, garantindo a compatibilidade com os modelos utilizados.

```
#transformar texto em numero
from sklearn.preprocessing import LabelEncoder

for coluna in X.columns:

    if X[coluna].dtype=="object":

        le=LabelEncoder()

        X[coluna]=le.fit_transform(
            X[coluna].astype(str)
        )

le_y=LabelEncoder()

y=le_y.fit_transform(
    y.astype(str)
)
```

Na segunda etapa, foi efetuado o tratamento de dados inconsistentes e ausentes. Inicialmente,

valores infinitos foram substituídos por valores nulos (*NaN*). Em seguida, os campos sem informação foram preenchidos utilizando a média dos valores da respectiva variável. Esse procedimento permitiu eliminar problemas que poderiam comprometer o treinamento e a avaliação dos modelos, garantindo maior consistência ao conjunto de dados.

```
#limpar dados problematicos
import numpy as np

X=X.replace(
    [np.inf,-np.inf],
    np.nan
)

X=X.fillna(
    X.mean()
)
```

5. MODELAGEM

Para a etapa de modelagem, foram selecionados três algoritmos de aprendizado de máquina amplamente utilizados em tarefas de classificação. A escolha desses métodos teve como objetivo comparar diferentes abordagens de previsão e avaliar qual delas apresentaria melhor desempenho na identificação dos níveis de burnout presentes na base de dados.

5.1. Árvore de Decisão

A Árvore de Decisão foi escolhida por sua capacidade de gerar modelos de fácil interpretação, permitindo visualizar de forma clara como as variáveis influenciam o resultado final. Além disso, esse algoritmo é capaz de identificar relações não lineares entre os atributos e a variável alvo, tornando-se uma alternativa interessante para a análise dos fatores associados ao burnout.

5.2. KNN (K Nearest Neighbors)

O algoritmo KNN foi selecionado por sua simplicidade e eficiência em problemas de classificação. Seu funcionamento baseia-se na comparação entre registros semelhantes, classificando novos casos de acordo com seus vizinhos mais

próximos. Dessa forma, o modelo pode identificar padrões presentes nos dados sem a necessidade de construir uma estrutura complexa de treinamento.

5.3. Regressão Logística

A Regressão Logística foi escolhida por ser um dos algoritmos mais utilizados em problemas de classificação. Além de apresentar baixo custo computacional e facilidade de implementação, esse método permite estimar a probabilidade de ocorrência de cada classe, servindo como uma importante referência para comparação com os demais modelos utilizados no estudo.

6. CONSTRUÇÃO DO COMITÊ

Para a construção do comitê de classificação, foi adotada a estratégia de votação majoritária (*Majority Voting*), na qual todos os modelos participantes possuem o mesmo peso durante o processo de decisão. Nesse método, a classe prevista pela maioria dos algoritmos é definida como resultado final da classificação.

A escolha dessa abordagem foi motivada pelo fato de que os modelos utilizados apresentam formas distintas de interpretar os dados e identificar padrões. Embora cada algoritmo possui níveis de desempenho diferentes, suas previsões fornecem perspectivas complementares sobre o problema analisado. Dessa forma, atribuir o mesmo peso a cada modelo permite que suas contribuições sejam consideradas de maneira equilibrada, buscando aumentar a robustez e a confiabilidade das previsões realizadas pelo comitê.

7. RESULTADOS E MÉTRICAS

O desempenho dos modelos foi avaliado utilizando a métrica de precisão (*accuracy*), que mede a proporção de classificações corretas realizadas pelo algoritmo em relação ao total de amostras analisadas. Os resultados obtidos foram os seguintes:

- **Árvore de Decisão:** 0,905 (90,5% de precisão);
- **KNN (K Nearest Neighbors):** 0,898 (89,8% de precisão);
- **Regressão Logística:** 0,934 (93,4% de precisão).

Com base nos resultados apresentados, observa-se que a Regressão Logística obteve o

melhor desempenho entre os modelos avaliados, alcançando uma precisão de 93,4%. A Árvore de Decisão apresentou desempenho próximo, com 90,5% de precisão, enquanto o KNN registrou 89,8%. Apesar das diferenças observadas, todos os modelos demonstraram capacidade satisfatória de identificar os padrões presentes na base de dados e realizar previsões relacionadas aos níveis de burnout dos funcionários.

8. DISCUSSÃO

A análise dos resultados demonstra que a Regressão Logística apresentou o melhor desempenho entre os modelos avaliados, alcançando a maior taxa de precisão. Esse resultado indica que o algoritmo foi o mais eficiente na identificação dos padrões presentes na base de dados, tornando-se a alternativa mais confiável para a realização das previsões propostas neste trabalho.

Embora a Árvore de Decisão e o KNN também tenham obtido resultados satisfatórios, seus níveis de precisão foram inferiores aos da Regressão Logística. Ainda assim, esses modelos contribuíram para a análise comparativa, permitindo avaliar diferentes abordagens de aprendizado de máquina aplicadas ao problema. Os resultados obtidos evidenciam que técnicas de Inteligência Artificial podem ser utilizadas de forma eficaz na identificação de fatores relacionados ao burnout e na previsão de seus níveis a partir das características dos profissionais analisados.

9. CONCLUSÃO

Neste trabalho, foram aplicadas técnicas de Inteligência Artificial e Aprendizado de Máquina para analisar dados relacionados à saúde mental de profissionais da área de Tecnologia da Informação, com foco na identificação e previsão dos níveis de burnout. A partir da utilização da base de dados Employee Mental Health & Burnout Dataset, foi possível realizar o pré-processamento das informações, treinar diferentes modelos de classificação e comparar seus desempenhos.

Os resultados obtidos demonstraram que todos os algoritmos avaliados apresentaram níveis satisfatórios de precisão, sendo a Regressão Logística o modelo de melhor desempenho, alcançando 93,4% de precisão. A Árvore de Decisão e o KNN também obtiveram resultados relevantes, contribuindo para a análise comparativa e para a construção do comitê de classificação.

Além de permitir a avaliação dos modelos, o projeto evidenciou a importância do tratamento adequado dos dados e da escolha dos algoritmos para a obtenção de previsões confiáveis. Dessa forma, conclui-se que técnicas de aprendizado de máquina podem ser

utilizadas de maneira eficaz para identificar padrões relacionados ao burnout e auxiliar na compreensão de fatores associados à saúde mental no ambiente de trabalho.

Por fim, o desenvolvimento deste trabalho proporcionou uma aplicação prática dos conceitos estudados na disciplina de Inteligência Artificial, permitindo explorar etapas fundamentais de um projeto de aprendizado de máquina, desde o pré-processamento dos dados até a avaliação dos resultados obtidos.